

Exploration de bibliothèques numériques et veille scientifique

Contexte : nous nous intéressons à identifier les sujets « tendance » dans les publications scientifiques d'un domaine, en France et en Europe.

En France, nous disposons d'une bibliothèque numérique institutionnelle : HAL (<https://hal.science/>). Tous les laboratoires CNRS, INRAE, INSERM, CEA... doivent y déposer leurs publications et les rendre accessibles gratuitement. Les publications sont accompagnées de métadonnées vérifiées.

Il n'y a pas encore d'équivalent européen mais la ressource OpenAlex (<https://openalex.org/>) essaye d'agrégier les catalogues de nombreuses bibliothèques numériques et permet ainsi d'identifier les publications européennes.

L'objectif est double :

- au final : il s'agit de dresser une cartographie de thèmes présents dans les publications d'un domaine donné en exploitant : titres des publications, résumés, mots clés, dates de publication, noms des laboratoires des auteurs etc.
 - Estimer à quel point les publications françaises dans HAL sont identifiées par OpenAlex. S'il s'avère que les publications choisies dans HAL sont dans OpenAlex, il est alors inutile d'interroger les deux ressources pour comparer les publications françaises avec celles des autres pays européens et seule OpenAlex suffit.
- 1) **Etape 1** : HAL. La première étape consiste à extraire un ensemble de publications depuis la plateforme HAL à partir des APIs d'interrogation et un domaine (thème, mots-clés etc.) scientifique que vous choisirez. Il s'agit ensuite d'enregistrer les données et méta-données recueillies dans un Dataframe pour y effectuer des analyses globales : nombre de publications par année, nombre de publications par mot-clé, laboratoires ou villes des auteurs, etc.
 - 2) **Etape 2** : Effectuer la même opération avec les APIs OpenAlex (<https://developers.openalex.org/>) puis isoler les publications françaises.
 - 3) **Etape 3** : Comparer les listes des publications françaises dans HAL et dans OpenAlex. Utiliser pour cela l'identifiant DOI et, s'il est absent, le titre de l'article. Analyser les résultats : publications communes ou seulement dans HAL etc.
 - 4) **Etape 4** (optionnelle) : Exploiter des représentations neuronales des résumés des publications pour représenter graphiquement les thèmes année après année. Vous pourrez utiliser par une 'modèle de thème' comme BERTopic (<https://maartengr.github.io/BERTopic/index.html>).

Etape 1.

La documentation de l'API HAL est disponible ici : <https://api.archives-ouvertes.fr/docs/search>

L'obtention des publications se fera via des appels de requête contenant les mots-clés et les propriétés des articles recherchés.

Il faudra utiliser la bibliothèque Python « requests » (client HTTP) : <https://pypi.org/project/requests/>

Les données seront obtenues par l'appel à la méthode get de requests en passant la requête en argument. Les réponses sont au format JSON, données que l'on pourra ensuite transférer dans un data frame pour les analyser, filtrer etc.

Exemple proche :

```
keywords = "(quantum OR qubit OR qbit)"

query = "q=title_t:"+keywords+"&q=abstract_t:"+keywords+"&fq=producedDateY_i:[\"2015 TO 2020\"]&fl=authFullName_s,title_s & facet=true & facet.pivot=producedDateY_i,docType_s & wt=json"
```

```
try:
    requete = "https://api.archives-ouvertes.fr/search/?"+query
    reponses = requests.get(requete, timeout=(300,300))
except requests.ReadTimeout:
    print ("temps limite atteint")

j = json.loads(reponses.text)

liste = j['facet_counts']['facet_pivot']['producedDateY_i,docType_s']
```

L'extraction des informations utiles de la réponse en JSON doit donner lieu à un data frame de la forme :

11 rows x 7 columns							Static output	
id	title_s	journalTitle_s	publicationDateY_i	publicationDateM_i	publicationDateD_i	abstract_s	authFullName_s	
0	Quantum computing : a short introduction.,Info...	NaN	2019	12.0	30.0	In this short introd...	Thomas Cluzel,Claude Mazel,David R.C. Hill	
1	Feedback exponential stabilization of open qua...	NaN	2019	10.0	30.0	In this thesisi, we ...	Weichao Liang	
2	Measurement-based quantum computation beyond q...	NaN	2022	2.0	22.0	Measurement-based qu...	Robert Ivan Booth	
3	Photonic Resources for the Implementation of Q...	NaN	2022	12.0	2.0	The security of mode...	Simon Neves	
4	Industrial approach to quantum dots in fully-d...	NaN	2022	12.0	14.0	Electron spin qubits...	Ioanna Kriekouki	
...	...	...	...	...	...	...	...	
1448	Control of light emission of quantum emitters ...	Light: Science and Applicati...	2023	7.0	13.0	Light emission of eu...	Martin Montagnac,Yoann Brûlé,Aurélien Cuche,Je...	
1449	On the Bi diffusion from (001) GaAsBi-GaAs qua...	5th international workshop o...	2014	7.0	NaN	NaN	Alexandre Arnoult,Aurélien Kuck,Hajer Makhlouf...	
1450	Nanotechnology practical teaching at school an...	2016 IEEE Nanotechnology Ma...	2016	10.0	NaN	In the last two deca...	Marc Respaud,Hélène Tap,Jérémie Grisolia,Géran...	
1451	Integration of the Rhombohedral BiSb(0001) Top...	ACS Applied Materials & Inte...	2021	8.0	4.0	Bismuth-Antimony all...	Dima Sadek,Daya S Dhungana,Roland Coratger,Cor...	
1452	All-sky search for long-duration gravitational...	Classical and Quantum Gravity	2018	3.0	22.0	NaN	B Abbott,R Abbott,T Abbott,M Abernathy,F Acern...	

Il devra avoir au minimum pour colonnes :



['Title', 'Source', 'Publication Year', 'Publication Month', 'Publication Day', 'Abstract', 'Authors']

De manière à rendre plus pertinente l'analyse des résumés et des titres, il sera utile de supprimer les mots outils (stopwords).

On emploiera pour cela la bibliothèque Python NLTK : <https://www.nltk.org/>

Et l'on pourra s'aider de : <https://medium.com/analytics-vidhya/removing-stop-words-with-nltk-library-in-python-f33f53556cc1>

Des statistiques globales sur la distribution des mots pourront ensuite être réalisées en utilisant la méthode FreqDist de NLTK, puis un nuage de mots avec la bibliothèque WordCloud : <https://pypi.org/project/wordcloud/>. Ces deux étapes permettront la création de graphiques comme :



Cette analyse pourra être conduite sur les mots des titres et/ou des résumés mais aussi sur celles des noms des auteurs et de leurs laboratoires.

On se propose ensuite de représenter graphiquement l'évolution de l'usage des mots les plus fréquents par périodes temporelles. Cela permettra de savoir quels sont les mots clés et les thèmes qui apparaissent et disparaissent au fil des ans.

Enfin, on s'intéressera à mesurer les collaborations entre laboratoires et leur évolution. De quels pays ou villes sont-ils issus ? Quelles sont les collaborations les plus fréquentes ?

Etape 2. OpenAlex

L'API OpenAlex est décrite ici : <https://developers.openalex.org/>

Comme pour HAL, il est possible d'obtenir directement les métadonnées d'une publication :
Exemple : <https://api.openalex.org/works?filter=doi:10.1038/s41586-021-03380-y>

Et par programme pour rechercher à partir du DOI :

```

import requests

doi = "10.1038/s41586-021-03380-y"

# Méthode 1 : identifiant direct
url = f"https://api.openalex.org/works/https://doi.org/{doi}"

# Méthode 2 : filtre
# url = f"https://api.openalex.org/works?filter=doi:{doi}"

response = requests.get(url, headers={"mailto": "ton@email.com"})
data = response.json()

print(data["title"])
print(data["publication_year"])
print(data["cited_by_count"])

[1] ✓ 0.4s
... People systematically overlook subtractive changes
2021
200

```

Et à partir d'un titre :

```

def search_by_title(query, max_results=5):
    url = "https://api.openalex.org/works"
    params = {
        "filter": f"title.search:{query}",
        "select": "title,publication_year,doi,cited_by_count,authorships",
        "per_page": max_results,
        "mailto": "ton@email.com"
    }

    response = requests.get(url, params=params)
    data = response.json()

    for work in data["results"]:
        print(work["title"])
        print(f"    {work['publication_year']} - citations : {work['cited_by_count']}")
        print(f"    DOI : {work.get('doi', 'N/A')}")
        print()

    search_by_title("deep learning protein structure prediction")

[2] ✓ 0.9s
... Improved protein structure prediction using potentials from deep learning
2020 - citations : 3395
DOI : https://doi.org/10.1038/s41586-019-1923-7

Deep learning methods in protein structure prediction
2020 - citations : 287
DOI : https://doi.org/10.1016/j.csbj.2019.12.011

```